

PEDRO HENRIQUE GAIOSO & JÚLIO CÉSAR

Federated Learning: Challenges, Methods, and Future Directions

Seminário de Computação Distribuída

Análise aprofundada do artigo de Li et al. (IEEE Signal Processing Magazine, 2020)

Contextualização

A transição do processamento centralizado para a era da inteligência na borda da rede

A Mudança de Paradigma

A Explosão na Borda

Historicamente, algoritmos exigiam que rios de dados brutos fossem enviados para grandes data centers corporativos.

Hoje, bilhões de dispositivos geram dados massivos localmente.

Essa abordagem centralizada esbarrou em limites críticos: custos de largura de banda, latência de rede e, principalmente, **violação de privacidade** (GDPR, LGPD).




Centralizado vs Federado

A Inversão do Fluxo

O Federated Learning (FL) propõe enviar o modelo até os dados, em vez de enviar os dados até o modelo.


- O armazenamento e o processamento de dados confidenciais permanecem estritamente no dispositivo.
- O servidor orquestra o aprendizado global.
- Evita-se a criação de um "ponto único de falha" com dados de usuários expostos em bancos de dados gigantes.



Arquitetura Iterativa

O ciclo federado opera em rodadas síncronas:

1. O servidor seleciona clientes disponíveis.
2. O modelo global atual é feito download para os nós.
3. Dispositivos treinam localmente.
4. Apenas as **atualizações de pesos** (gradientes) sobem para a nuvem.
5. O servidor agrega (ex: média) para atualizar o modelo global.





Os Quatro Pilares de Desafios

A dissecção das barreiras que separam a teoria da otimização da prática

Os Quatro Pilares



1. Comunicação

Limitações severas de banda em redes móveis e assimetria (upload muito menor que download).



2. Sistemas

Discrepâncias massivas de hardware entre datacenters robustos e pequenos sensores IoT.



3. Estatística

Distribuição de dados Não-IID, gerando divergência severa nos modelos globais.



4. Privacidade

Vulnerabilidades críticas na transmissão de gradientes permitindo ataques de inferência.

Desafio 1: Gargalos de Rede

O Custo do Upload

Transferir milhões de parâmetros de redes neurais profundas (DNNs) repetidamente consome rapidamente a franquia do usuário e satura a banda.

Estratégias de Redução

O artigo lista soluções essenciais:


- **Atualizações Locais:** Treinar mais épocas localmente (cômputo denso, rede esparsa).
- **Sparsificação:** Enviar apenas as atualizações críticas.
- **Quantização:** Reduzir precisão matemática (ex: de 32 para 8-bits).

Desafio 2: Heterogeneidade de Sistemas



Poder Computacional

Variação brutal de RAM e processamento limitando o treinamento padronizado em toda a rede.



Restrições de Bateria

Dispositivos desligam ou recusam a computação para evitar esgotar a bateria do usuário.



Stragglers

Nós com conexões intermitentes atrasam a etapa de agregação síncrona do servidor.

Desafio 3: O Paradoxo Não-IID

Divergência Estatística

No FL, os dados refletem **comportamentos humanos locais** (linguagem, hábitos, horários).

Eles Não São Independentes e Identicamente Distribuídos (Não-IID).

Isso causa **Weight Divergence**: a otimização local de um nó aponta para um mínimo local totalmente diferente do objetivo global, impedindo o modelo de convergir.




FIGURE 1. IID thinking from the machine learning problem (a) is either (b) (i.e., independent and identically distributed) by an IID learning strategy characterizing its non-IID and then solved by

Desafio 4: Privacidade e Segurança



Ataques de Inversão de Modelo

Ocultar dados não é o bastante. Inspeccionar as atualizações de gradiente permite que adversários reconstruam dados sensíveis da origem.



Privacidade Diferencial (Differential Privacy)

Adição deliberada de ruído estatístico nos gradientes antes de subirem, garantindo que o servidor não consiga isolar a contribuição individual de ninguém.



Computação Multipartida Segura (SMC)

Protocolos de criptografia homomórfica onde a média das atualizações é calculada sem que o servidor consiga ver os valores individuais (blind aggregation).

Metodologia Proposta

Modelagem Matemática: Do FedAvg ao framework robusto FedProx

O Risco Empírico Distribuído

A formalização canônica abordada no artigo define o objetivo global como a minimização da função de perda agregada sobre todos os "m" nós:

$$\min_w F(w) = \sum_{k=1}^m p_k F_k(w)$$

O Problema do FedAvg

O algoritmo baseline realiza passos de SGD locais irrestritos. Em ambientes Não-IID, esses passos afastam o modelo local irreparavelmente do ótimo global.

Desperdício Sistêmico

Dispositivos que não conseguem completar todas as épocas (por falta de bateria) têm seus resultados descartados.

A Inovação: Framework FedProx

Para lidar com a divergência estatística, os autores propõem o **FedProx**, adicionando um **termo proximal** à função objetivo de cada dispositivo:

$$\min_w h_k (w ; w^t) = F_k (w) + \frac{\mu}{2} \| w - w^t \|^2$$

Como Funciona a Regularização?

O termo (multiplicado por μ) penaliza atualizações que se afastam demais do modelo global da rodada anterior (w^t). Isso funciona como uma "âncora", impedindo que dados locais severamente enviesados destruam a convergência global.

Metodologia: Benchmark LEAF

O artigo validou as formulações estruturando o LEAF, um benchmark com datasets naturalmente particionados e altamente heterogêneos:


Dataset	Natureza do Dado	Número de Usuários (Nós)	Tamanho Total
FEMNIST	Classificação de Caracteres Manuscritos	3.550	805.263 imagens
CelebA	Visão Computacional (Atributos)	9.343	200.288 imagens
Shakespeare	Linguagem Natural (Next-word)	1.129	4.226.158 amostras
Sent140	Análise de Sentimento (Textos)	660.120	1.600.498 tweets

Resultados de Acurácia



O uso da regularização proximal melhora a acurácia absoluta em até **22%** comparado ao baseline em redes instáveis, tolerando envios de dispositivos stragglers e suavizando a divergência.

Estabilidade de Convergência



Diferente do FedAvg que sofre picos caóticos, o FedProx força uma **descida de gradiente mais suave e monotônica**, mesmo recebendo atualizações conflitantes e parciais dos clientes móveis.


Sistemas Reais: Concept Drift

O Dinamismo do Mundo Real

O artigo ressalta que implementações em produção (como teclados preditivos) sofrem de **Concept Drift**.

Os padrões subjacentes dos dados mudam ao longo do tempo (ex: novas gírias). Modelos federados precisam de mecanismos de *lifelong learning* para não ficarem obsoletos.

Há também o desafio de integrar novos dispositivos após o modelo base estar maduro.



Futuro da Área (Future Directions)

Fairness (Equidade)

Garantir que a otimização não favoreça apenas as classes majoritárias ou usuários de smartphones topo de linha com mais dados.



Personalização

Mudar da abordagem "one-size-fits-all" para meta-learning, onde o modelo global atua como base para uma fina sintonia no dispositivo local.



Robustez Bizantina

Projetar redes imunes a ataques onde dispositivos maliciosos entram na rede unicamente para envenenar a atualização do modelo.

Obrigado!

Agradecemos a atenção nesta Avaliação por Pares.

Pedro Henrique Gaioso & Júlio César

Computação Distribuída – Análise de Artigo Científico

Image Sources




<https://wikibon.com/wp-content/uploads/loT-Edge-Computing-Wikibon-Silicon-Angle-Media.png>

Source: theclubresearch.com




https://miro.medium.com/1*aiU5snfwEFtgt2kVzrL1lg.png

Source: medium.com



https://miro.medium.com/v2/resize:fit:1400/1*eO1mZ1gxM7rNRodeanpFuQ.png

Source: medium.com



https://static.vecteezy.com/system/resources/previews/070/587/876/large_2x/detailed-macro-shot-of-a-computer-cpu-processor-chip-photo.jpg

Source: www.vecteezy.com



<https://preview.redd.it/apples-low-battery-screen-frustrates-me-to-no-end-v0-o2n4xm3q5os01.png?width=640&crop=smart&auto=webp&s=374aa1001d0f661049a75bad824a0da14ee44db9>


Source: www.reddit.com



<https://media.istockphoto.com/id/1288130003/vector/loading-progress-circle-in-black-and-white.jpg?s=612x612&w=0&k=20&c=eKCLbwdoJy5a7oofoh9AEt6Mp7dc1p79L>

Source: www.istockphoto.com

Image Sources



<https://datasciences.org/wp-content/themes/dslabNew/images/datasciences/IIDness.png>

Source: datasciences.org



https://cdn.prod.website-files.com/660ef16a9e0687d9cc27474a/662c3c84d06a3de5f69b1fe4_654037a380b2cf37f88b7589_concept_drift3.png

Source: www.evidentlyai.com